

TAREA III MAGISTER EN DATA SCIENCE

ASIGNATURA : Machine Learning II
NOMBRE PROFESOR : Bastián Galasso
EMAIL : b.galasso@edu.uai.cl

1. INSTRUCCIONES

En el dataset incluido en el sitio web, usted encontrará unas variables asociadas a distintas medidas correspondientes a dos tipos de arroces de Turquía, especie Osmacik y especie Cammeo. Dentro de las variables encontrará las siguientes variables:

- Area: Corresponde al número de píxeles dentro del grano de arroz
- Perimeter: Corresponde a la distancia recorrida por los píxeles del contorno del grano de arroz
- Major_Axis_Length: Corresponde al eje mayor de la elipse (el grano es una elipse en si)
- Minor_Axis_Length: Corresponde al eje menor de la elipse o grano.
- Eccentricity: Corresponde a una medida de qué tan redondo es el grano
- Convex_Area: Conteo de píxeles de la envoltura convexa mínima del grano
- Extent: Corresponde a la relación de la región formada por el grano y el bounding box asociado en la imagen.
- Class: Cammeo u Osmancik.

Con lo anterior, realice lo siguiente:

1. Realice una exploración de datos para ver qué datos existen, cuales de ellos entregan información relevante para el problema y cuales no, eliminación (si corresponde) de datos nulos y duplicados, entre otros.
2. Seleccione las variables que utilizará para realizar la modelación, y con ello determine el modelo a utilizar. Realice la modelación correspondiente y reporte métricas de desempeño del modelo.
3. Realice una optimización de hiper-parámetros para obtener un mejor desempeño del modelo. Para este punto, las métricas de desempeño reportadas en el punto anterior deben mejorar.
4. Entregue un reporte de métricas de su modelo final, matriz de confusión y conclusiones sobre lo obtenido. ¿Cree que su modelo es un buen modelo? Comente.
5. Utilice técnicas para realizar una interpretación local del modelo, de manera de comprender qué variables afectan a las distintas predicciones.

El set de datos entregado en este link, viene en formato ARFF, por lo que para poder leerlo desde Python puede utilizar el siguiente código:

```
import scipy.io.arff as arff
import pandas as pd

data = arff.loadarff(open('FILE_PATH', 'rt'))
df = pd.DataFrame(data[0])
df.head()
```

Las tareas deben entregarse en un jupyter notebook, dejando sus comentarios en chunks de markdown y no comentado dentro del código. El jupyter debe venir completamente ejecutado para una corrección más fácil.

Dado que es la tarea final del curso, se exigirá más rigurosidad en sus análisis y en la elaboración de sus respuestas, para que sean ordenados y claros en sus ideas.

Plazo hasta el domingo 27 de Septiembre a las 23:59.